

Étape 3 (DPO) : double fonction en une seule passe d'entraînement
Alignement des préférences cliniques + apprentissage du format de sortie contractuel (F3)

[CONCEPTUEL / PRÉVU] Étape 3 (DPO) non implémentée dans le code à ce jour (aucun script d'entraînement DPO n'existe, cf. README.md, section « 3. DPO »). Ce diagramme est prospectif : il illustre ce que le cahier des charges prévoit, pas un entraînement réellement exécuté. Théorie complète (dérivation de la perte DPO) : docs/references/livre_theorique_llm_triage_chsa.md, §6.

1. Entrée : dataset DPO de préférences cliniques

Prompt / contexte (x)

Patiente : « Douleur thoracique oppressive depuis 30 min, irradiant au bras gauche, SpO2 : 92 % »

Réponse choisie
(y_w, « chosen »)

Décision : ESI-1 / Code rouge
Raisonnement : voies respiratoires en danger + ECG
Format : structuré (JSON + balises ChatML)

Réponse rejetée
(y_l, « rejected »)

Décision : ESI-3 / Code jaune
Raisonnement : « Prendre du paracétamol et attendre »
Format : texte libre, non structuré

2. Traitement DPO en une seule passe (single-pass DPO fine-tuning), [CONCEPTUEL]

Modèle en entraînement
(politique π_θ)
Qwen3-1.7B-Base + LoRA

Point de départ prévu : le checkpoint SFT-LoRA déjà réel, publié sur mombasstic/chsa-triage-sft-lora (verdict de convergence « saine »), jamais encore utilisé comme point de départ d'un entraînement DPO. π_{ref} : copie gelée de ce même checkpoint (cf. livre théorique §6.3).

Log-vraisemblance
 $\log \pi_\theta(y_w | x)$

Log-vraisemblance
 $\log \pi_\theta(y_l | x)$

Perte DPO

$$L_{DPO}(\theta; \pi_{ref}) = -E [\log \sigma(\beta \cdot \log(\pi_\theta(y_w|x)/\pi_{ref}(y_w|x)) - \beta \cdot \log(\pi_\theta(y_l|x)/\pi_{ref}(y_l|x)))]$$

Formule dérivée en détail (Bradley-Terry → politique optimale sous contrainte KL → perte DPO) dans le livre théorique, §6.2 et §6.3 ; non reprise ici.

Fonction 1 : alignement des préférences cliniques

Augmente la probabilité relative de y_w face à y_l : pénalise le sous-triage (ESI-3 au lieu d'ESI-1) sur des symptômes graves, via le ratio par rapport au modèle de référence π_{ref} .

Fonction 2 : apprentissage du format de sortie contractuel

En préférant y_w (structuré), le modèle apprend aussi les délimiteurs exacts de bloc ChatML (<|im_start|>assistant) et la structure JSON valide requise, dans la MÊME descente de gradient : aucune passe d'entraînement séparée pour le format.

3. Sortie prévue : inférence du modèle aligné, [CONCEPTUEL]

Contexte d'entrée
(add_generation_prompt=True)

<|im_start|>user
Symptômes : « Dyspnée aiguë, cyanose, FR>30/min, SpO2 88 % »<|im_end|>
<|im_start|>assistant

Sortie générée
(schéma JSON minimal, F3)

```
{
  "niveau": "ESI-1",
  "categorie": "détresse respiratoire aiguë",
  "ressources_estimees": "déchocage / réanimation immédiate"
}
```

Valeurs illustratives, cf. cahier des charges F3/§9 : aucun schéma Pydantic {niveau, categorie, ressources_estimees} formel n'existe encore dans le code (cf. src/chsa_triage/application/metriques_evaluation_baseline.py).

Une version enrichie (champs type orientation, justification_medicale, action_sih) pourrait être proposée plus tard pour une intégration avec un SIH hospitalier réel, mais n'appartient ni au critère d'acceptation du POC (§9) ni à F3: elle n'apparaîtrait jamais comme un champ du JSON ci-dessus.