



Centre Hospitalier
Saint-Aurélien (CHSA)

Développez le POC d'un agent de triage médical
Optimiser l'orientation des
patients et soutenir le personnel
soignant aux urgences

Spécialisation d'un modèle de base par Fine-Tuning Supervisé (SFT) et alignement par préférences pour le déploiement d'un LLM médical au service de la santé publique.

Rafael CEREZO MARTIN

Septembre 2026



Centre Hospitalier
Saint-Aurélien (CHSA)



Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-LoRA Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions


Introduction

Proof of concept d'un agent IA capable d'assister le triage médical au Centre Hospitalier Saint-Aurélien, à partir d'un modèle de langage open-source affiné sur des données cliniques réelles.

Ce que ce projet met en œuvre :

- Pipeline de données complet : 6 corpus sources → dataset pivot anonymisé (134 883 exemples, RGPD)
- Architecture hexagonale : ports/adaptateurs, testable et modulaire
- Fine-tuning LoRA de Qwen3-1.7B-Base (SFT, puis DPO)
- Suivi d'expérimentation réel (MLflow) et déploiement cloud (HF Jobs, GPU)

	Étape	Objectif
1	Préparation des données	Collecter, nettoyer et structurer le corpus pour garantir sa qualité avant l'entraînement.
1.bis	Baseline zero-shot	Mesurer le point de départ, avant tout entraînement
2.1	SFT-LoRA	Entraîner le modèle sur les données du projet
2.2	Évaluation post-SFT	Mesurer l'amélioration réelle, chiffrée
3.1	DPO	Aligner le modèle sur les préférences
3.2	Évaluation post-DPO	Valider les gains d'alignement et s'assurer que le comportement du modèle reflète les préférences cibles sans régression
4	Déploiement	Intégrer et mettre en production le modèle optimisé pour le rendre opérationnel auprès des utilisateurs finaux.







Centre Hospitalier
Saint-Aurélien (CHSA)

1

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Architecture



Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions



1.1

5. Conclusions



```

"1": "1",
"clinical_case": "Homme, 58 ans, majoration de dyspnée chez un BPCO connu depuis 20 ans.\n\nExamen d'entrée : N Constantes (N - FC = 138bpm/min - PA = 130/80 mmHg de deux bras - FR = 40/min SpO2 90% N - SCu Tirage aux sternal N - Cynose N - Sursaut N - Auscultation : N - Bronchi bilatéraux et sibilants N - Tympanisme bilatéral N - Hépatomégale douleuruse Reflux hépatogastrique N - Turgescence jugulaire N - Hippocratisme digital N - Cynose unguéale N - ATCD N - Peur (80 FA) N - BPCO N - Traitement habituel N 82 mgétiques N N HOM : depuis 1 semaine : ne peut plus faire, expectations sales N N 2h après, malgré le traitement initial, patient tient des propos incohérents et désorienté.",
"cc_question_number": "1",
"question": "Quels sont éléments de gravité au moment de l'arrivée du patient ? ",
"answer": "FC>125bpm Terrain : ATCD de BPCO, insuffisance respiratoire chronique (signes de détresse respiratoire : dyspnée, tirage aux sternal, tachypnée, SpO2<90% N - FR>30/min - Sursauts N - Cynose N - Tirage N - Signes d'insuffisance droite N - Hépatomégale douleuruse N - Reflux N - Turgescence.",
"medical_subject": "Emergency Medicine",
"question_type": "Reasoning"

```



"id": "7593",
"clinical_case": "Monsieur R, âgé de 37 ans, forestier de son métier, doit partir travailler pendant 2 ans au Gabon dans la région de Lambaréné. Monsieur R, à l'intention de se faire accompagner de son épouse âgée de 36 ans et de son fils âgé de 5 ans, ils logeront à quelques kilomètres du forêt de M. R., de par son métier, passera la plupart de son temps au milieu des bois. Ils consultent 4 mois avant le départ pour se renseigner au sujet des vaccinations et de la chimioprophylaxie du paludisme. Vous lui expliquez les conseils d'hygiène, les éléments de protection essentiels et les différents modes de contamination des maladies présentes dans la région".
"question": "Au sujet des vaccinations ?",
"answer_a": "Le vaccin contre la fièvre jaune est obligatoire",
"answer_b": "Le vaccin contre la fièvre jaune peut se faire au cabinet du médecin traitant",
"answer_c": "Le vaccin contre le choléra est un vaccin qui assure une protection supérieure à 80%",
"answer_d": "Le vaccin contre le paludisme B est conseillé mais il ne se trouve pas en pharmacie, il faut contacter l'hôpital",
"answer_e": "Les vaccinations contre le tétanos et la poliomyélite ne sont pas indispensables",
"correct_answers": "A",
"task": "QCU",
"medical_subject": "Infectious Diseases",
"question_type": "Understanding"



```

"id": "11399",
"clinical_case": "Plusieurs jours après un contact avec un enfant atteint d'oreillons, une fillette de 6 ans développe un état fébrile à 40° rapidement suivi d'une parotidite unilatérale. L'atteinte se calèbre de bilatérale et la température se normalise. Vers le 6e jour cependant, apparaissent des céphalées intenses et des vomissements incoercibles.",
"question": "Quelle(s) proposition(s) peut (peuvent) s'appliquer à l'épidémiologie de la maladie ? ",
"answer_a": "Transmission manportée",
"answer_b": "La phase de contagiosité dure 8 jours",
"answer_c": "Maladie strictement humaine",
"answer_d": "Confère une immunité",
"answer_e": "Transmission indirecte possible",
"correct_answer": "C,D",
"task": "QCM",
"medical_subject": "Infectious Diseases",
"question_type": "Understanding"
}

```



A

QCM



MedQuAD

Questions/réponses médicales



Paires choisies/rejetées

```
{
  "id": "7230abc9b0fe633b772410bc081025f63c39990548131d6334bd2eff6",
  "question": "Parmi les affirmations suivantes, une seule est fausse, indique laquelle: les portiques alpha",
  "answers": [
    "answer_0": "Sont formés de noyaux d'hélium",
    "answer_1": "Sont peu pénétrantes",
    "answer_2": "Sont arrêtés par une feuille de papier",
    "answer_3": "Sont peu ionisantes"
  ],
  "correct_answers": 4,
  "number_correct_answers": 0
}
```

```
{
  "type": "susceptibility",
  "Question": "Who is at risk for Lymphocytic Choriomeningitis (LCM)? ?",
  "Answer": "LCM infections can occur after exposure to fresh urine, droppings, saliva, or nesting materials from infected rodents. Transmission may also occur when these materials are directly introduced into broken skin, the nose, the eyes, or the mouth, or presumably, via the bite of an infected rodent. Person-to-person transmission has not been reported, with the exception of vertical transmission from infected mother to fetus, and rarely, through organ transplantation."
}
```

```

    "prompt_id": "WikiInstruct,8304",
    "label_type": "length",
    "prompt": "Investigate the intricacies of immunometabolism, a distinct subfield of immunology that examines the interconnection between cellular metabolic processes and the functional attributes of immune cells. ...",
    "chosen": {
      "content": "Investigate the intricacies of immunometabolism, a distinct subfield of immunology that examines the interconnection between cellular metabolic processes and the functional attributes of immune cells. ...",
      "role": "user"
    },
    {
      "content": "Immunometabolism is an emerging field of study that explores the intersection between cellular metabolic processes and the functional attributes of immune cells. ...",
      "role": "assistant"
    },
    },
    "rejected": [
      {
        "content": "Investigate the intricacies of immunometabolism, a distinct subfield of immunology that examines the interconnection between cellular metabolic processes and the functional attributes of immune cells ...",
        "role": "user"
      },
      {
        "content": "Immunometabolism is an emerging field that explores how metabolic processes influence the function and fate of immune cells, and vice versa, how immune responses can shape cellular metabolism. ...",
        "role": "assistant"
      }
    ],
    "metadata": {
      "golden_answer": null,
      "chosen": {
        "model": "Mixtral-8x7B-Instruct",
        "score": 5,
        "rank": 1,
        "evaluation": "This response is exceptionally detailed and well-structured, providing an in-depth exploration of the mechanisms of immunometabolism and its implications. ..."
      },
      "rejected": {
        "model": "Llama-3-8B-UltraMedical",
        "score": 4,
        "rank": 2,
        "evaluation": "The response provides a comprehensive overview of immunometabolism, detailing the mechanisms and implications for metabolic diseases. ..."
      }
    },
    "feedback": "Assistant A provides a detailed and comprehensive response that thoroughly explains the concept of immunometabolism, the mechanisms involved, and its implications in various diseases, particularly metabolic disorders. ..."
  }
}

```



1.2

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

• 2.1 Architecture

- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

● 3.1 Préparation de données

- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

● 4.1 Architecture


- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD

● 4.5 Inférence



Open-Ended Questions ,
question + réponse courte libre

medical_subject
Distinct 31





Centre Hospitalier
Saint-Aurélien (CHSA)

1.3

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.3 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions


1. Préparation et structuration des données

Collecter les 4 corpus bruts / construire_dataset_pivot

Pivot original jamais mute :

L'anonymisation écrit dans un fichier séparé, texte source toujours disponible pour contrôle.

```
{
  "identifiant": "chsa-mediqa1-136e614fde31",
  "source": "MediQA1",
  "type_exemple": "sft",
  "langue": "fr",
  "symptomes": "Quels sont éléments de gravité au moment de l'arrivée du patient ?",
  "antecedents": null,
  "constantes_vitales": null,
  "prompt": [
    {
      "role": "user",
      "contenu": "Quels sont éléments de gravité au moment de l'arrivée du patient ?"
    }
  ],
  "completion": [
    {
      "role": "assistant",
      "contenu": "FC>125bpm\n Terrain : ATCD de BPCO, insuffisance respiratoire chronique (hippocratismes digital)\n Signes de détresse respiratoire avec hypoxie et hypercapnie :\n - SpO2<90%\n - FR>30/min\n - Sueurs\n - Cyanose\n - Tirage\n Signes d'insuffisance droite\n - Hépatomégalie douloureuse\n - Reflux\n - Turgescence"
    }
  ],
  "chosen": [],
  "rejected": [],
  "niveau_confiance": "moyenne",
  "anonymise": false,
  "split": null
}
```





Centre Hospitalier
Saint-Aurélien (CHSA)

1.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- **1.4 Anonymisation**
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO


4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / AnonymiserDatasetUseCase





Centre Hospitalier
Saint-Aurélien (CHSA)

1. Préparation et structuration des données

Collecter les 4 corpus bruts / **Anonymisation** / PII = **Personally Identifiable Information**

Renforcement RGPD du pipeline d'anonymisation

Corrections ciblées avant l'échantillon SFT

1.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- **1.4 Anonymisation**
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

`_construire_analyzer_multilangue()`

Faux négatifs NIR, hôpitaux, dossiers patients

Les recognizers par défaut de Presidio (PERSON, EMAIL, PHONE, LOCATION...) ne couvrent pas les identifiants français spécifiques : numéro de sécurité sociale (NIR, 15 chiffres), numéros de dossier interne, codes hospitaliers. Ces identifiants directs traverseraient l'anonymisation intacts.

Décision

Enregistrer des **PatternRecognizer** personnalisés dans le registre de l'AnalyzerEngine avant de le retourner, analyzer.registry.add_recognizer(...), avec un motif regex pour le NIR et tout identifiant interne observé dans les corpus réels.

`_construire_operateurs()`

Date absolue vs durée relative

Aujourd'hui, toute expression temporelle passe par un opérateur DEFAULT uniforme : « le 15 mars 1987 » (identifiant) et « il y a 3 mois » / « pendant 2 semaines » (durée de traitement, non identifiante) sont traités de façon identique, la seconde catégorie perd une information clinique utile au modèle.

Décision

Un opérateur dédié par type d'entité, operators["DATE_TIME"] = ..., avec une logique custom qui distingue selon le motif capturé : date calendaire précise → masquer ; durée relative → conserver intacte.

`anonymiser()`

Âge, normaliser avant que Presidio ne le voie

Une expression comme « âgé de 34 ans » ne doit jamais atteindre l'analyseur sous une forme qui la fait capturer par le recognizer DATE_TIME puis supprimer, l'âge est une donnée clinique nécessaire (pédiatrique / adulte / gériatrique), pas un identifiant direct.

Décision

Nouvelle étape de prétraitement, avant l'appel à analyzer() : détecter le motif d'âge et le remplacer par un tranche d'âge (0-12, 13-17, 18-64, 65+), il n'est alors plus jamais candidat à la suppression.

`anonymiser_dataset.py`

Traçabilité, jamais de mutation en place

Un design précédent modifiait le pivot en place — une erreur de stratégie ou de reconnaître perdait le texte source, sans retour en arrière possible ni contrôle qualité a posteriori.

Décision

--dataset n'est plus jamais modifié, lu seul.
Le résultat est écrit dans --sortie, un fichier séparé
Le statut « déjà anonymisé » se détermine par la présence de l'identifiant dans --sortie, ce qui permet un contrôle qualité par simple comparaison des deux fichiers.

`anonymiser()`

Entités chevauchantes ou coupées

Deux entités détectées peuvent se chevaucher (span partagé) ou une entité peut être coupée par un saut de ligne, laissant une partie du texte sensible visible.

Décision

Le moteur AnonymizerEngine de Presidio résout déjà les chevauchements par score/longueur, ce n'est donc pas une zone non couverte.

`controler_qualite_anonymisation.py`

méthode d'échantillonnage de contrôle

Le script a déjà accès au texte original et au texte anonymisé côte à côte, mais l'échantillon de contrôle actuel ne distingue pas les exemples « avec entité » des exemples « sans entité », un faux négatif silencieux dans ce dernier groupe ne serait jamais audité.

Décision

Détection triviale, texte_original == texte_anonymise sur tous les champs signale un cas « propre ». Ajouter un strate d'échantillonnage dédiée à ces cas, au lieu de les traiter comme le reste.



1.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO


4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / AnonymiserDatasetUseCase





1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / AnonymiserDatasetUseCase

1.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT


3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions



scripts/anonymiser_par_lots.sh

```
while true; do
    DEJA_TRAITES= $(compter_lignes "${SORTIE}")
    if [ "${DEJA_TRAITES}" -ge "${TOTAL_PIVOT}" ]; then
        break
    fi
    HORODATAGE= $(date +%Y%m%d_%H%M%S)

    LOG_FICHIER= "${LOG_DIR}/anonymisation_${ITERATION}_${HORODATAGE}.log"
    DERNIER_LOG= "${LOG_FICHIER}"
    echo "=== Iteration ${ITERATION} : ${DEJA_TRAITES}/${TOTAL_PIVOT}
    traite avant ce lot ==="

    set +e
    uv run python interfaces/cli/ anonymiser_dataset.py \
        --dataset "${PIVOT}" --sortie "${SORTIE}" \
        --strategie "${STRATEGIE}" --limite "${TAILLE_LOT}" \
        2>&1 | tee "${LOG_FICHIER}"
    CODE_SORTIE=${PIPESTATUS[0]}
    set -e

    if [ "${CODE_SORTIE}" -ne 0 ]; then
        echo "Erreur : anonymiser_dataset.py a echoue (code
        ${CODE_SORTIE}) a l'iteration ${ITERATION}. Voir ${LOG_FICHIER}." >&2
        exit "${CODE_SORTIE}"
    fi

    APRES= $(compter_lignes "${SORTIE}")
    if [ "${APRES}" -le "${DEJA_TRAITES}" ]; then
        echo "Erreur : aucune progression a l'iteration ${ITERATION}
        (${DEJA_TRAITES} -> ${APRES}) traite(s). Arrêt pour eviter une boucle
        infinie. Voir ${LOG_FICHIER}." >&2
        exit 1
    fi

    ITERATION=$((ITERATION + 1))
done
```



Centre Hospitalier
Saint-Aurélien (CHSA)

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / Durée totale: **19 heures, 24 minutes et 6 secondes**

Résultats de l'Anonymisation Presidio (Couverture RGPD)

- **Complétude du Dataset** : 100% du dataset pivot source anonymisé (134 883 exemples traités sur 27 exécutions).
- **Détection globale** : 91,1% des exemples contiennent au moins une PII, pour un total de 1,68M d'entités détectées et masquées (stratégie replace).

Variabilité selon la source :

- **Faible présence de PII** : FrenchMedMCQA (35,4% avec entités), typique de Q&A académiques/médicales pures.
- **Traces modérées à fortes** : MediQAI (57,2%) et MedQuAD (88,2%).
- **Pratiquement systématique** : UltraMedical-Preference (99,2%), reflétant un volume élevé de noms, lieux ou terminologies spécifiques.

Environnement Matériel et Exécution

- **Calcul CPU pure** : Traitement réalisé sur un processeur ultra-portable quad-core (Intel i7-8550U) sans accélération GPU.
- **Ressources contraintes** : RAM contenue à 8 Go au total (5,8 Go utilisables sous l'instance WSL2 Ubuntu 24.04).
- **Impact sur la performance** : Explique la durée totale de 19h 24m pour les 135k exemples, démontrant la faisabilité du pipeline d'anonymisation sur une infrastructure de type laptop/commodity hardware.

=== Anonymisation complete : 134883/134883 exemples ===

Iterations : 27

Duree totale approx. : 69846s

Dernier log : logs/anonymisation/anonymisation_27_20260910_040918.log

```
2026-09-10 04:47:08,424 [anonymiser_dataset] *****
2026-09-10 04:47:08,427 [anonymiser_dataset] -----
2026-09-10 04:47:08,427 [anonymiser_dataset] Rapport RGPD cumule (comptage du total reel du dataset
pivot source + fusion)
2026-09-10 04:47:59,399 [anonymiser_dataset] rapport RGPD JSON.....:
data/processed/rapport_anonymisation_rgpd.json
2026-09-10 04:47:59,399 [anonymiser_dataset] rapport RGPD Markdown.....:
data/processed/rapport_anonymisation_rgpd.md
4883 exemples anonymises (strategie=replace, limite=5000).
Resultat ecrit dans data/processed/dataset_pivot_anonymise.jsonl (le pivot original
data/processed/dataset_pivot.jsonl n'a pas ete modifie).
```

Rapport RGPD cumule (toutes executions d'anonymisation confondues) :

Anonymise (cumule).....: **134883/134883** exemples du dataset pivot (**100.0%**)

Avec >=1 entite detectee.: **122907/134883** exemples anonymises (**91.1%**)

Entites detectees (total): 1687092

Executions ayant contribue: 27


FrenchMedMCQA : 594 traitees (cumule), 210 avec entite (**35.4%**)

MedQuAD : 16359 traitees (cumule), 14426 avec entite (**88.2%**)

MediQAI : 20849 traitees (cumule), 11920 avec entite (**57.2%**)

UltraMedical-Preference : 97081 traitees (cumule), 96351 avec entite (**99.2%**)

Résultats de l'Anonymisation RGPD par Source (Total: 134 883)



Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

1.4



Centre Hospitalier
Saint-Aurélien (CHSA)

1.4

Introduction

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- **1.4 Anonymisation**
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation

134 883

exemples pivot
(147 204 bruts, 12 321 doublons ecartes)


RGPD

Anonymisation Presidio + spaCy
par vagues incrementales

Révision humaine persiste des
candidats PII résiduelle avant toute
publication.

Explicit prompt
(recommandé par trl)

trl.DPOTrainer
(accepte le format explicite)



data/processed/dataset_pivot_anonymise.jsonl

```
{
  "identifiant": "chsa-ultramedical_preference-0b01ab4bd9e03d14",
  "source": "UltraMedical-Preference",
  "type_exemple": "dpo",
  "langue": "en",
  "identifiant_source_brute": "MedInstruct-52k,4646",
  "symptomes": "",
  "antecedents": null,
  "constantes_vitales": null,
  "prompt": [
    {
      "role": "user",
      "contenu": "Determine the best protocol for treating a patient with this type of cancer based on their diagnosis details.\n\n<AGE_ADULT> female was recently diagnosed with an estrogen receptor-positive (ER+), progesterone receptor-negative (PR-), <INFO_MASQUEE>/neu receptor-positive (+) .."
    }
  ],
  "completion": [],
  "chosen": [
    {
      "role": "assistant",
      "contenu": "The treatment of breast cancer is complex and depends on various factors, including the stage of the disease, the specific characteristics of the cancer, and the patient's overall health and preferences. The patient described has an estrogen receptor-positive (ER+), progesterone receptor-negative (PR-), <INFO_MASQUEE>/neu receptor-positive ( <INFO_MASQUEE>) invasive ductal carcinoma with lymph node involvement but no distant metastasis. ..."
    }
  ],
  "rejected": [
    {
      "role": "assistant",
      "contenu": "Based on the information provided, the patient has a hormone receptor-positive (ER+), <INFO_MASQUEE>/neu receptor-positive (+), and lymph node-positive breast cancer. ..."
    }
  ],
  "niveau_confiance": "haute",
  "anonymise": true,
  "split": null
}
```



Centre Hospitalier
Saint-Aurélien (CHSA)

1.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
 - 1.2 Profiler Corpus
 - 1.3 Dataset Pivot
 - **1.4 Anonymisation**
 - 1.5 Découpage en Splits
- ### 2. SFT + LoRA
- 2.1 Architecture
 - 2.2 Baseline Evaluation
 - 2.3 SFT Train
 - 2.4 SFT-Lora Train
 - 2.5 Evaluation Post-SFT
- ### 3. DPO
- 3.1 Préparation de données
 - 3.2 DPO Train
 - 3.2 Évaluation Post-DPO
- ### 4. Déploiement
- 4.1 Architecture
 - 4.2 vLLM Server
 - 4.3 FastAPI
 - 4.4 CI/CD
 - 4.5 Inférence
- ### 5. Conclusions


1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / Contrôler Qualité Anonymisation

Flux d'exécution du contrôle qualité de l'anonymisation.

Le traitement se déroule en quatre étapes principales :

- **Parse Arguments :** Récupération de la configuration CLI (fichiers sources, taille de l'échantillon, graines aléatoires et seuils).
- **Prepare Adapters :** Mises en place des dépendances (accès aux données via JsonlDatasetRepository et vérification des entités nommées via spaCy).
- **Use Case Execute :** Le cœur métier (ControlerQualiteAnonymisationUseCase) orchestre le contrôle en comparant les jeux de données original et anonymisé.
- **Log Final Info :** Formatage et exportation des résultats détaillés sous forme de rapports JSON et Markdown horodatés."






1.4

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / Contrôler Qualité Anonymisation

Logique métier du cas d'usage ContrôlerQualiteAnonymisation.

- **Trois sorties distinctes** : À partir du couple d'objets ExemplePivot, le composant réalise trois traitements spécifiques.
- **Détection fine** : La recherche de fuites génère un CandidatPiiResiduelle, tandis que la détection des faux positifs alimente la structure CandidatFauxPositifAnonymisation (incluant le fragment masqué).
- **Exemples illustratifs** : En parallèle, la fonction `_conserver_exemple_illustratif` extrait un objet ExempleControle dédié à la documentation et à la traçabilité dans le rapport."



Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- **1.4 Anonymisation**
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions



Introduction

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Anonymisation / Controler Qualite Anonymisation

rapport_controle_qualite_anonymisation.md

```

formater_rapport_controle_qualite_markdown
chemin_markdown.write_text(
    formater_rapport_controle_qualite_markdown(
        controle,
        horodatage,
        arguments.dataset,
        arguments.anonymise,
        arguments.taille_echantillon,
        total_disponible,
        statistiques_cumulees,
    ),
    encoding="utf-8",
)

```

[rapport controle qualite anonymisation.json](#)

```

"horodatetime": "2026-09-10T04:55:34+00:00",
"dataset_original": "data/processed/dataset_pivot.jsonl",
"dataset_anonymise":
"data/processed/dataset_pivot_anonymise.jsonl",
"nombre_exemples_observes": 200,
"candidates_pii_residuelle": [
  {
    "identifiant": "source": "champ": "langue":
"type_motif": "passage": "verdict":
  },
  ...
  "candidates_faux_positifs": [
    {
      "identifiant": "source": "champ": "fragment_masque":
"texte_original": "texte_anonymise": "verdict":
    },
    ...
    "exemples_par_source": {
      "UltraMedical-Preference": [
        {
          "identifiant": "champ":
"texte_original": "texte_anonymise":
        },
        ...
        "stratum_sans_entite_detectee": {
          "nombre_disponibles": 10866,
          "nombre_observes": 40,
          "candidates_pii_residuelle": [
            {
              "identifiant": "source": "champ": "langue":
"type_motif": "passage": "verdict":
            },
            ...
            "exemples": [
              {
                "identifiant": "champ": "texte_original":
"texte_anonymise":
              },
              ...
            ]
          }
        }
      ]
    }
  ]
}

```


Rapport de controle qualite: anonymisation (comparaison original/anonymise)

1. Compteurs par catégorie d'entité anonymisée (rapport RGPD cumulé, Partie 1)




2. Candidats de PII résiduelle (regex sur texte anonymisé + seconde opinion spaCy)


Passages confirms




Passages en attente de revision humaine



3. Candidats de faux positifs de l'anonymisation (termes masques sans necessite)



4. Exemples reels (original -> anonymise) par source




5. Stratum dedie : exemples SANS entite detectee (item 3)

Candidats confirmés (faux négatif complet possible de Presidio)



Candidats en attente de revision humaine



Exemples relus (texte inchangé)





1.5

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence



5. Conclusions

1. Préparation et structuration des données

Collecter les 4 corpus bruts / Découpage en splits

Architecture et l'injection de dépendances pour la phase de découpage en splits (Train, Val, Test).

- **Architecture Hexagonale** : Le cas d'usage DecouperSplitsUseCase réside au cœur de la couche Application. Il dépend uniquement de l'abstraction RepositoryLectureEcriture définie dans le domaine.
- **Inversion de dépendance** : L'adaptateur concret JsonlDatasetRepository de la couche Infrastructure est injecté à l'exécution via le script CLI decouper_splits.py.
- **Découpage** : Cette séparation garantit que la logique de répartition est totalement indépendante du stockage sous-jacent."





Centre Hospitalier
Saint-Aurélien (CHSA)

1.5

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions


1. Préparation et structuration des données

Collecter les 4 corpus bruts / Découpage en splits

Algorithme de stratification et répartition


Logique interne de la méthode `executer()` pour le découpage stratifié :

- **Étape 1 — Filtrage initial** : Partition des exemples anonymisés entre `deja_assignes` (ayant déjà un split) et `candidats` (sans split).
- **Étape 2 — Échantillonnage** : Détermination du nombre d'exemples à prélever segùn `n` (tirage stratifié si $\$n < \text{total}$).
- **Étape 3 — Stratification** : Regroupement des nouveaux candidats par strate (`type_exemple`, `source`).
- **Étape 4 — Décompte existant** : Comptage initial des splits déjà attribués lors d'exécutions précédentes.
- **Étape 5 — Calcul des tailles** : Mélange reproductible (`rng`) et calcul des quotas `test`, `val` et `train` par strate.
- **Étape 6 — Attribution du split** : Affectation séquentielle des nouveaux exemples aux splits et mise à jour des compteurs.
- **Étape 7 — Persistance $\$O(N)\$$** : Sauvegarde groupée des nouveaux exemples enrichis et retour du décompte total.



train/val/test

Splits stratifiés, jamais reassignés d'une exécution à l'autre






Centre Hospitalier
Saint-Aurélien (CHSA)

2.1

2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

Architecture / Architecture



Introduction

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

• 2.1 Architecture

- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions



2.2

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement


- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

Baseline Evaluation / Métriques

1. **taux_exact_match(paires)** — **Exact Match** : compare le texte généré par rapport au texte de référence après normalisation (minuscules, suppression de la ponctuation, espaces réduits). Elle renvoie le pourcentage de correspondances exactes.
2. **f1_moyen(paires)** — **F1 au niveau des tokens** : (même principe que le F1 de SQuAD) mesure le chevauchement de mots entre le texte généré et le texte attendu, sans exiger une correspondance exacte.
3. **exactitud_classification_niveau(paires)** — **Exactitude de classification du niveau** : *accuracy* de classification du niveau de triage ESI. Elle extrait le champ *niveau* d'un objet JSON {niveau, categoria, ressources_estimees} aussi bien dans la réponse générée que dans la référence, puis les compare.



	Exact match	F1 moyen (token)	Latence moyenne	Échecs d'inférence
CPU (Q4_K_M)	0,000	0,037	~21,6 s	36/278
GPU (bf16)	0,000	0,043	~7,3 s	0/278

• La baseline GPU est plus rapide, plus fiable (zero echec) et legèrement meilleure en F1 : reference retenue.



Centre Hospitalier
Saint-Aurélien (CHSA)

2.2

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- **2.2 Baseline Evaluation**
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

Baseline Evaluation

Zero-Shot du modèle de base

0.000

EXACT MATCH

0 / 278 réponses identiques

0.043

F1 MOYEN (TOKEN)

*Chevauchement lexical
très faible*

7 295 ms

LATENCE MOYENNE

*≈ 7,3 s par génération
(bf16, GPU)*

0

ÉCHECS D'INFÉRENCE

*278 / 278 générations
complétées*

Le modèle **Qwen3-1.7B-Base**, sans adaptation, ne suit pas le format de sortie attendu du triage : il produit du texte libre plutôt qu'une structure exploitable en aval par l'application.

Le **F1 moyen** de 0,043 et l'**Exact Match** nul confirment un décalage quasi total entre les réponses générées et les réponses de référence du split test.

La latence de ~7,3 s / génération sert de référence brute avant optimisation (LoRA, puis vLLM en Semaine 4).

Aucun échec technique d'inférence : le pipeline d'évaluation (chargement modèle, génération, scoring) est **validé de bout en bout** sur les 278 exemples.

⚠ POINT BLOQUANT IDENTIFIÉ

Exactitude de classification du **niveau ESI** : **non calculable** (0 paire comparable sur 278). Le modèle de base ne produit pas de complétion au format JSON structuré attendu {niveau, categorie, ressources_estimees}, empêchant toute comparaison automatique sur ce critère clinique.



Centre Hospitalier
Saint-Aurélien (CHSA)

2.3

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO


4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

SFT Train / Point d'entrée: Entraînement SFT-LoRA réel





2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

SFT Train / Point d'entrée: Entraînement SFT-LoRA réel

2.3

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT


3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions





SFT Train / Configuration, Chargement et Ajustement Fin Supervisé du modèle base.

Introduction

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT



3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence



5. Conclusions





2.4

- 1. Préparation de données
 - 1.1 Télécharger Corpus
 - 1.2 Profiler Corpus
 - 1.3 Dataset Pivot
 - 1.4 Anonymisation
 - 1.5 Découpage en Splits
- 2. SFT + LoRA
 - 2.1 Architecture
 - 2.2 Baseline Evaluation
 - 2.3 SFT Train
 - 2.4 SFT-Lora Train
 - 2.5 Evaluation Post-SFT
- 3. DPO
 - 3.1 Préparation de données
 - 3.2 DPO Train
 - 3.2 Évaluation Post-DPO
- 4. Déploiement
 - 4.1 Architecture
 - 4.2 vLLM Server
 - 4.3 FastAPI
 - 4.4 CI/CD
 - 4.5 Inférence
- 5. Conclusions





Centre Hospitalier
Saint-Aurélien (CHSA)

2.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- **2.4 SFT-Lora Train**
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. Entraînement Initial par Fine-Tuning Supervisé (SFT) SFT Train / Entraînement SFT-LORA et Sauvegarde de métadonnées.

- QLoRA 4-bit, rang LoRA 16 sur 4 modules d'attention (q_proj, k_proj, v_proj, o_proj).
- 3 epoques, 342 pas, environ 20 minutes - premier entraînement réel du projet mene a bien.
- Verdict de convergence : SAINE.
- Poids LoRA publies de facon persistante : mombasstic/chsa-triage-sft-lora.

Depot dataset HF

mombasstic/chsa-triage-sft-metrics

Run

sft-lora-16092026-reconstruit

☒ Auto-actualiser

Actualiser maintenant

Suivi d'entrainement SFT-LoRA (en vivo)

Etape actuelle	Perte train	Perte validation	Norme gradient
342	-	1.6365	-

Verdict de convergence : **saine** (34 etapes analysees,
perte_validation absente : surapprentissage non detectable)






Centre Hospitalier
Saint-Aurélien (CHSA)

2.5

2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

Evaluation Post-SFT



Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions



Centre Hospitalier
Saint-Aurélien (CHSA)

2.5

Introduction

1. Préparation de données
 - 1.1 Télécharger Corpus
 - 1.2 Profiler Corpus
 - 1.3 Dataset Pivot
 - 1.4 Anonymisation
 - 1.5 Découpage en Splits
2. SFT + LoRA
 - 2.1 Architecture
 - 2.2 Baseline Evaluation
 - 2.3 SFT Train
 - 2.4 SFT-Lora Train
 - **2.5 Evaluation Post-SFT**
3. DPO
 - 3.1 Préparation de données
 - 3.2 DPO Train
 - 3.2 Évaluation Post-DPO
4. Déploiement
 - 4.1 Architecture
 - 4.2 vLLM Server
 - 4.3 FastAPI
 - 4.4 CI/CD
 - 4.5 Inférence
5. Conclusions

2. Entraînement Initial par Fine-Tuning Supervisé (SFT)

Evaluation SFT / Baseline vs Post-SFT, Le modèle a-t-il appris ?

Comparaison sur le même split test (278 exemples, chsa-triage-baseline-test)

RUN	EXACT MATCH	F1 (TOKEN)	LATENCE MOYENNE
Baseline CPU (zero-shot)	0.000	0.037	—
Baseline GPU (zero-shot, bf16)	0.000	0.043	7 295 ms
Post-SFT (checkpoint LoRA)	0.000	0.112	11 553 ms

×2,6

GAIN F1 VS MEILLEUR BASELINE

0,043 → 0,112 (+160 %)

Mesure le chevauchement lexical entre la réponse générée et la référence, c'est la métrique pertinente pour du texte médical libre. Il a presque triplé par rapport au meilleur baseline.

Conclusion

Le SFT + LoRA a bien fait évoluer le modèle vers le vocabulaire et les formulations attendues du triage médical.

0.000

EXACT MATCH

Constant sur les 3 runs, limite de la métrique, pas du modèle

Pourquoi l'Exact Match reste à 0
Exige une correspondance caractère par caractère avec la réponse de référence complète, quasi impossible sur du texte médical en langage libre.

Conclusion

Ce n'est pas un échec du fine-tuning, c'est une limite intrinsèque de la métrique pour ce type de tâche.

+58 %

LATENCE

7 295 ms → 11 553 ms

La hausse de latence (+58 %) coïnciderait avec des réponses plus longues et plus complètes après SFT, au lieu de générations tronquées comme sur le modèle de base, hypothèse cohérente avec le gain de F1, à valider par une analyse de longueur de sortie.



Centre Hospitalier
Saint-Aurélien (CHSA)

3.1

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO


4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. DPO (Direct Preference Optimization) Aliénation / Double fonction à l'entraînement

- Aligne les préférences cliniques
- Enseigne le format de sortie contractuel (<think>+JSON) requis par le SIH





Centre Hospitalier
Saint-Aurélien (CHSA)

3.2

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- **3.2 DPO Train**
- 3.2 Évaluation Post-DPO

4. Déploiement


- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. DPO (Direct Preference Optimization)

DPO Train

⚠ Le DPO a d'abord révélé un problème réel a l'évaluation (dégénérescence de génération), diagnostique, corrige (beta=0,3) et réconfirme à l'échelle réelle : le fil conducteur de la section 3.



Diagnostiquer, corriger, reverifier

- 1. taux=5e-6, lot=4 : boucle complete avec succes, mais l'evaluation plante en OutOfMemoryError. Cause verifiée : per_device_eval_batch_size jamais fixe (defaut reel = 8, double du lot d'entrainement). Corrige : per_device_eval_batch_size = taille_lot.
- 2. taux=5e-6, lot=1 : premier run complet bout-en-bout. Verdict sous_apprentissage ; rewards/accuracies=0,30 (pire que le hasard), rewards/margins negatif.
- 3. taux=5e-5, lot=4 (recette corrigee) : rewards/accuracies 0,30 -> 0,625 (train) / 0,75 (eval), margins redevient positif. Verdict encore sous_apprentissage, mais probable faux negatif (le seuil de convergence herite du SFT ignore rewards/accuracies et rewards/margins).

SAINE

Verdict de convergence
(premier verdict sain DPO du projet)

72,5 %

rewards/accuracies
(rewards/margins = +3,00)

1h44

Duree réelle
(estimation initiale : 30-60 min)

Run complet, 5000 exemples

- taux_apprentissage=5e-5, taille_lot=4, beta=0,1 - recette corrigee d'apres les 3 runs precedents.
- rewards/chosen=-1,72, rewards/rejected=-4,72 : le modele prefere bien 'chosen' a 'rejected', comme attendu.
- Confirme la lecture faite a 100 exemples : le verdict sous_apprentissage etait un faux negatif du seuil herite du SFT, pas un echec d'apprentissage. Poids publies : mombasttic/chsa-triage-dpo-lora.
- Ce premier run a l'echelle réelle utilise encore beta=0,1 : l'evaluation qui suit (3.3) y decouvre un probleme reel, corrige puis reconfirme a cette meme echelle.



3.3

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO


4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

2. DPO (Direct Preference Optimization)

Évaluation Post-DPO



Comparaison sur le même split test (278 exemples, chsa-triage-baseline-test)

RUN	EXACT MATCH	F1 (TOKEN)	LATENCE MOYENNE
Baseline CPU (zero-shot)	0.000	0.037	—
Baseline GPU (zero-shot, bf16)	0.000	0.043	7 295 ms
Post-SFT (checkpoint LoRA)	0.000	0.112	11 553 ms
Post-DPO	0.000	0.110	11 200 ms

- rewards/margins=+3,00 est très élevé pour $\beta=0,1$: signe cohérent d'un ancrage trop faible à π_{ref} , pas seulement d'un paramètre de décodage à l'évaluation.
- β relève à 0,3 : gain confirme d'abord sur le checkpoint pas cher à 100 exemples, PUIS sur le run complet à 5000 (verdict sain, rewards/accuracies=0,75) - aucune régression en passant à l'échelle.



Centre Hospitalier
Saint-Aurélien (CHSA)

4. Déploiement Architecture de Services

4.1

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT


3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions





Centre Hospitalier
Saint-Aurélien (CHSA)

4.2

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions


4. Déploiement Launch vLLM server

1. A travers d'un Job dans HF

```
hf jobs run \  
--flavor l4x1 \  
--timeout 30m \  
--secrets HF_TOKEN \  
--expose 8000 \  
vllm/vllm-openai:latest \  
vllm serve Qwen/Qwen3-1.7B-Base \  
--enable-lora \  
--lora-modules dpo=mombasstic/chsa-triage-dpo-lora \  
--max-lora-rank 16
```

Hint: Exposed ports are reachable at (requires an HF token with read access to the job):
<https://6ab3ebc352d0dbd7f1d85915--8000.hf.jobs>

```
[api_utils.py:347]  
[api_utils.py:347]  
[api_utils.py:347] version 0.30.0  
[api_utils.py:347] model Qwen/Qwen3-1.7B-Base  
[api_utils.py:347]  
[api_utils.py:347]
```




Healthcheck

```
curl -s -o /dev/null -w "%{http_code}\n" \  
-H "Authorization: Bearer $(cat ~/.cache/huggingface/token)" \  
https://6ab3ebc352d0dbd7f1d85915--8000.hf.jobs/health
```

Inférence par ligne de commande sur un Job

```
curl -H "Authorization: Bearer $(cat ~/.cache/huggingface/token)" -H "Content-Type: application/json" \  
https://6ab3ebc352d0dbd7f1d85915--8000.hf.jobs/v1/chat/completions \  
-d '{"model": "dpo", "messages": [{"role": "user", "content": "Douleur thoracique oppressive depuis 30 min, irradiant au bras gauche"}]}'
```


2. A travers d'un Dockerfile dans HF



1. Créer le Space Docker/GPU
2. Configurer le secret HF_TOKEN
3. Configurer le secret CHSA_CLE_API_DEMO
4. Publier le Dockerfile
5. Publier demarrer.sh
6. Publier le code source
7. Publier le README

8. Reconstituer et démarrer
hf spaces restart mombasstic/chsa-triage-api
hf spaces wait mombasstic/chsa-triage-api
9. Vérifier que l'API répond
curl <https://mombasstic-chsa-triage-api.hf.space/sante>

Healthcheck





Vérifier que l'API répond (toujours 200, même si vLLM charge encore)

```
curl https://mombasstic-chsa-triage-api.hf.space/sante
# attendu : {"disponible":true,"detail":"serveur vLLM disponible"}
```

Tester une conversation réelle bout-en-bout via l'API

1. Démarrer une conversation

```
CONVERSATION_ID=$(curl -sS -X POST "$CHSA_BASE/conversations" \
-H "X-API-Key: $CHSA_CLE" | python3 -c "import sys,json;
print(json.load(sys.stdin)['conversation_id'])")
echo "conversation id=$CONVERSATION_ID"
```


2. Envoyer un message (répéter pour poursuivre l'entretien)

```
curl -sS -X POST
"$CHSA_BASE/conversations/$CONVERSATION_ID/messages" \
-H "X-API-Key: $CHSA_CLE" \
-H "Content-Type: application/json" \
-d '{"message": "Patient de 45 ans. douleur thoracique depuis 2 heures."}'
```


3. Demander le diagnostic (niveau ESI, catégorie, ressources, raisonnement)

```
curl -sS -X POST
"$CHSA_BASE/conversations/$CONVERSATION_ID/diagnostic" \
-H "X-API-Key: $CHSA_CLE"
```


Configuration utilisé pour l'inference à distance avec modele base (Coût de GPU)



Configuration de staging 1. Inference local avec modele Quantisé GGUF (Sans coût de GPU)



Configuration de staging 2. Tests local avec modele base. (Sans coût de GPU)



Introduction

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- **4.3 FastAPI**
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions



4.4

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO


4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- **4.4 CI/CD**
- 4.5 Inférence

5. Conclusions

4. Déploiement CI/CD

- Job tests : installe dev+local+api (+pyyaml), lance uv run pytest tests/ -q. 433 passed / 5 skipped au moment de l'écriture.
- Job docker-build (apres tests) : reconstruit l'image de l'API pour verifier que le Dockerfile build, sans jamais la publier ni la deployer.
- Le deployment des Spaces HF reste manuel par decision : jamais automatisé dans ce pipeline.
- Aucun job GPU/vLLM reel lance dans le cadre du deployment (le build Docker n'a pas pu etre verifie non plus dans ce bac a sable, WSL2 sans integration Docker Desktop).





Centre Hospitalier
Saint-Aurélien (CHSA)

4.5

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD

• 4.5 Inférence

5. Conclusions

4. Déploiement

Frontend Streamlit / Démarrer une conversation

Lancer le frontend Streamlit en local, pointé vers le Space réel

```
export CHSA_API_URL_BASE="https://mombasstic-chsa-triage-api.hf.space"
uv run streamlit run interfaces/web/app_test_inference.py
```

Entretien clinique de test (CHSA Triage)



la fièvre a monte touse et fatigue



- La pression artérielle est normale ? - Le rythme cardiaque normal? - L'état mental stable?

La réponse à ces questions permettra au médecin en charge des consultations urgentes (ou ambulatoire) de déterminer si une intervention immédiate doit être envisagée. Lorsqu'il n'y a pas assez d'éclaircissement sur certains aspects clés parmi ceux mentionnées ci-dessus, on peut demander plus précisément : 1/ Quel type(s) de douleur ressent-on ? 2 / Est-ce que vous avez eu déjà cette situation avec

Obtenir le diagnostic

Decrivez les symptomes du patient...



chsa-triage-audit-journal/journal_audit.jsonl

```
{
  "horodatage": "2026-09-25T12:38:50.180345+00:00",
  "type_evenement": "tour_entretien",
  "conversation_id": "366dd327-136a-4466-b8e0-a43c186c5113",
  "entree": "la fièvre a monte touse et fatigue ",
  "sortie": "- La pression artérielle est normale ? - Le rythme cardiaque normal? - L'état mental stable?\n\nLa réponse à ces questions permettra au médecin en charge des consultations urgentes (ou ambulatoire) de déterminer si une intervention immédiate doit être envisagée.\nLorsqu'il n'y a pas assez d'éclaircissement sur certains aspects clés parmi ceux mentionnées ci-dessus, on peut demander plus précisément :\n1/ Quel type(s) de douleur ressent-on ?\n2 / Est-ce que vous avez eu déjà cette situation avec",
  "version_modele": "mombasstic/chsa-triage-dpo-lora",
  "metadonnees": {}
}
...
```



Centre Hospitalier
Saint-Aurélien (CHSA)

4.5

Introduction

1. Préparation de données

- 1.1 Telecharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

4. Déploiement Frontend Streamlit Demander le diagnostic



le patient pèse 80kg



Le traitement préventif contre HFRS chez les personnes vivant près de zones endémiques consiste principalement en vaccination anti-HRVFV ; mais aussi en prophylaxie individuelle via des médicaments antimicrobiens telles que chloroquine, hydroxychloroquine, etc., ainsi que certaines vaccins non spécifiques dont nous parlerons ultérieurement

Obtenir le diagnostic

Format de diagnostic non respecte par le modele ; reponse brute :

<si>: Diagnostic de [catégorie] basé sur [...]

Diagnostic de maladie infectieuse grave selon échelle Système Informatisé de Triages Urgentes

(MEDICO-CLINIQUE>):

NIVEAU DE PRIORITE DANS LES CONSULTATIONS URGENCES ET AMBULATOIRES:

PRIORITÉ N° I: Les patients présentant soit une infection virale extrêmement contagieuse, soit une affection inflammatoire systémique sévère pouvant entraîner une insuffisance organique importante,

avec potentiellement risque mortel sans prise en compte de leur âge et de leurs conditions médicales existantes;

PRIORITÉ II: Tous autres cas nécessitant une attention rapide afin de limiter les conséquences graves possibles; Ceci inclut notamment tous types d'hypertension pulmonaire chronique, tout accident vasculaire cérébral, toute crise hypertensive intracrânienne; toutes infections bactérienne ou virales ayant pu provoquer une inflammation neurologique sérieuse, surtout lorsque celle-ci survient peu de jours auparavant; Enfin également toute pathologie cardiovasculaire métabolique comorbide associée à une hypertension artérielle élevée;

PRIORITÉ III: Aucune autre catégorie de consultation urgence où aucune complication grave n'est attendu

Decrivez les symptomes du patient...



```
{
  "horodatage": "2026-09-25T12:47:29.942155+00:00",
  "type_evenement": "diagnostic",
  "conversation_id": "366dd327-136a-4466-b8e0-a43c186c5113",
  "entree": " "
}

{
  "role": "user",
  "contenu": "J'ai un assistant de triage aux urgences qui aide un infirmier à recueillir les informations d'un patient. Pose UNE SEULE question à la fois, courte et cliniquement pertinente, pour mieux cerner les symptômes, les antécédents ou les constantes vitales du patient. Ne propose ni diagnostic ni niveau de priorité à ce stade : l'infirmier déclenchera lui-même le diagnostic final quand il aura jugé l'entretien suffisant.\n\nVoilà fièvre a monte toussé et fatigue "
},
{
  "role": "assistant",
  "contenu": "La pression artérielle est normale ? - Le rythme cardiaque normal? - L'état mental stable?\n\nVoilà réponse à ces questions permettra au médecin en charge des consultations urgentes (ou ambulatoires) de déterminer si une intervention immédiate doit être envisagée.\n\nVeuillez noter qu'il n'y a pas assez d'informations sur certains aspects clés parmi ceux mentionnés ci-dessus, on peut demander plus précisément :\n\n/ Quel type(s) de douleur ressentez-vous ?\n/ Est-ce que vous avez eu déjà cette situation avec ?
},
{
  "role": "user",
  "contenu": "La pression artérielle est normale, Le rythme cardiaque normal et L'état mental stable"
},
{
  "role": "assistant",
  "contenu": "3/ Avez-vous été hospitalisé récemment ?\n\n/ Comment se présente votre état général actuel?\n\n/ Que fait-il dans sa chambre depuis son arrivée ici"
},
{
  "role": "user",
  "contenu": "Il n'a pas été hospitalisé... il toussé et il a un mouchoir pour le nez "
},
{
  "role": "assistant",
  "contenu": "6/ Vous êtes marié(e), comment s'appellent vos enfants(les)?\n\n/ Votre poids avant cet événement était combien kg., puis quel temps mettez-vous à entrer deux repas.\n\n/ Vous continuez-vous quelque chose après avoir mangé... comme quoi...\n\n/ Si oui quels sont ses effets secondaires...?"
},
{
  "role": "user",
  "contenu": "pas d'enfants...mange chaque heure pas de médicaments "
},
{
  "role": "assistant",
  "contenu": "enfant unique .poids avt=kg , poids après =kg...mettre ....combinaison après manger.....effet secondaire"
},
{
  "role": "user",
  "contenu": "le patient pèse 80kg "
},
{
  "role": "assistant",
  "contenu": "Le traitement préventif contre HFRS chez les personnes vivant près de zones endémiques consiste principalement en vaccination anti-HRVFV ; mais aussi en prophylaxie individuelle via des médicaments antimicrobiens telles que chloroquine, hydroxychloroquine, etc., ainsi que certains vaccins non spécifiques dont nous parlerons ultérieurement"
}
},
{
  "sortie": " <si>: Diagnostic de [catégorie] basé sur [...]\n\nDiagnostic de maladie infectieuse grave selon échelle Système Informatisé de Triages Urgentes (<b>MEDICO-CLINIQUE>): \n\nNIVEAU DE PRIORITE DANS LES CONSULTATIONS URGENCES ET AMBULATOIRES:\n\nPRIORITÉ N° I:\nLes patients présentant soit une infection virale extrêmement contagieuse,soit une affection inflammatoire systémique sévère pouvant entraîner une insuffisance organique importante,\n\navec potentiellement risque mortel sans prise en compte de leur âge et de leurs conditions médicales existantes;\n\nPRIORITÉ II:\nTous autres cas nécessitant une attention rapide afin de limiter les conséquences graves possibles;\n\nCeci inclut notamment tous types d'hypertension pulmonaire chronique, tout accident vasculaire cérébral, toute crise hypertensive intracrânienne; toutes infections bactérienne ou virales ayant pu provoquer une inflammation neurologique sérieuse, surtout lorsque celle-ci survient peu de jours auparavant ;\n\nEnfin également toute pathologie cardiovasculaire métabolique comorbide associée à une hypertension artérielle élevée ;\n\nPRIORITÉ III:\nAucune autre catégorie de consultation urgence où aucune complication grave n'est attendu",
  "version_model": "mombasstic/chsa-triage-dpo-lora",
  "metadonnees": {
    "format_respecte": false
  }
}
```



5

Introduction

1. Préparation de données

- 1.1 Télécharger Corpus
- 1.2 Profiler Corpus
- 1.3 Dataset Pivot
- 1.4 Anonymisation
- 1.5 Découpage en Splits

2. SFT + LoRA

- 2.1 Architecture
- 2.2 Baseline Evaluation
- 2.3 SFT Train
- 2.4 SFT-Lora Train
- 2.5 Evaluation Post-SFT

3. DPO

- 3.1 Préparation de données
- 3.2 DPO Train
- 3.2 Évaluation Post-DPO

4. Déploiement

- 4.1 Architecture
- 4.2 vLLM Server
- 4.3 FastAPI
- 4.4 CI/CD
- 4.5 Inférence

5. Conclusions

Conclusions

Statut réel

- **Etape 1 (donnees)** : ✅ terminée - 134 883 exemples pivot, anonymisés et repartis en splits.
- **Etape 2 (SFT)** : ✅ réussie et validée - F1 token triple par rapport à la meilleure baseline.
- **Etape 3 (DPO)** : ✅ entraînée avec succès à l'échelle réelle ; dégradation à l'évaluation diagnostiquée et corrigée ($\beta=0,3$ + $\text{repetition_penalty}=1,2$), gain confirme à l'échelle réelle ($F1=0,110$, quasi identique au post-SFT, aucune régression en passant de 100 à 5000 exemples).
- **Etape 4 (déploiement)** : ✅ code écrit et testé, Space HF créé et déployé (Dockerfile + code réels poussés), actuellement en pause pour maîtriser le coût.

Ce qui reste ouvert

- **Garde-fou de sécurité clinique NF4** (juge LLM, $\text{safety} < 4/7$) : ⚠️ décision produite encore ouverte, non implémentée.
- **Space HF (GPU vLLM, API, Streamlit)** : ✅ créé et déployé, code réel poussé, actuellement en pause pour maîtriser le coût, ⚠️ jamais testé en conditions de charge réelle.
- **Tests de latence** : ✅ des mesures réelles existent déjà en local (CPU quantifié, 23 mesures, p50/p95), ⚠️ mais pas encore en conditions réelles de production (GPU, Space) ni sous charge/concurrence.
- **Classification du niveau ESI (F3) non calculable** : ⚠️ le dataset n'a pas encore de réponses de référence au format JSON structuré qu'exige cette métrique.



Q et R

Rafael CEREZO MARTIN

Septembre 2026